

---

# Aprendizagem por Reforço

Fabrício Barth

Maio de 2020


---

# Sumário

- Visão Geral
- Algoritmo Q-Learning
- Implementações
- Material de Consulta

# Visão Geral


Um agente aprende a resolver uma tarefa através de repetidas interações com o ambiente, por tentativa e erro, recebendo (esporadicamente) reforços (punições ou recompensas) como retorno.



## Visão Geral

- Este agente não tem conhecimento algum sobre a tarefa que precisa executar (heurísticas ou funções de utilidade específicas).
- A **tarefa** deste agente é executar uma **sequência de ações**, observar as suas **consequências** e aprender uma **política de controle**.

- A política de controle desejada é aquela que **maximiza** os reforços (*reward*) acumulados ao longo do tempo pelo agente:  $r_0 + \gamma r_1 + \gamma^2 r_2 + \dots$  onde  $0 \leq \gamma < 1$ .



## Exemplo

Início	Campo	Campo	Campo
Campo	Buraco	Campo	Buraco
Campo	Campo	Campo	Buraco
Buraco	Campo	Campo	<b>Objetivo</b>

### Ações:

- (0) Mover para Baixo; (1) Mover para Cima;
- (2) Move para Direita; (3) Move para Esquerda.


- Considerando que o local do objetivo, dos buracos e dos campos serão sempre os mesmos então temos **16** estados possíveis.
- Este problema tem **4** ações possíveis.
- Se o agente cair em um buraco ele recebe  $-1$  como recompensa, se ele ir para um campo ele recebe  $0$  e ao chegar no objetivo ele recebe  $1$ .
- Para que agente possa identificar uma política de controle ótima este agente precisa criar um **mapeamento** entre **estados** (S) e **ações** (A)

- Este mapeamento pode ser representado por uma função  $Q(S, A)$  onde  $S$  são todos os estados possíveis ( $s_1, s_2, \dots$ ) e onde  $A$  são todas as ações possíveis ( $a_1, a_2, \dots$ )

Q-table	$a_1$	$a_2$	$a_3$	$a_4$
$s_1$				
$s_2$				
$\dots$				
$s_n$				

- Para criar um **mapeamento**  $Q(S, A)$  é necessário executar o agente no ambiente considerando o **reforço** dado por cada ação.





reforço

	esquerda	baixo
S1	0	0
S2	0	-1
S3	-1	0
S4	0	0
S5	0	0

- Qual é a recompensa do agente se ele seguir os seguintes caminhos?
  - ★  $baixo \rightarrow baixo \rightarrow baixo \rightarrow esquerda \rightarrow esquerda \rightarrow esquerda \rightarrow direita$
  - ★  $baixo \rightarrow direita \rightarrow baixo \rightarrow esquerda \rightarrow esquerda \rightarrow baixo$
- Como é que o agente pode saber quais são as melhores ações em cada estado?

# Algoritmo Q-Learning

- A ideia é fazer com que o agente aprenda a função de mapeamento  $Q(S, A)$ . Ou seja, que seja capaz de identificar qual é a melhor ação para cada estado através das suas **experiências**.
- *Testando infinitas* vezes o ambiente. Ou seja, *testando infinitas* vezes as combinações entre **estados** ( $S$ ) e **ações** ( $A$ ).

Primeiro episódio ( $\gamma = 0.9$ ):

$$Q(s_1, baixo) \leftarrow r + \gamma \max_{a'} Q(s', a')$$

$$Q(s_1, baixo) \leftarrow 0 + 0.9 \times \max[0, 0, 0]$$

$$Q(s_3, esquerda) \leftarrow -1 + 0.9 \times \max[0, 0, 0, 0]$$

$$Q(s_n, esquerda) \leftarrow 1 + 0.9 \times \max[0, 0, 0, 0]$$

Q-table resultante da execução do 1º episódio.

<b>Q-table</b>	<i>esquerda</i>	<i>baixo</i>	<i>direita</i>	<i>cima</i>
$s_1$	0	0	0	0
$s_2$	0	-1	0	0
$s_3$	-1	0	0	0
$s_4$	0	0	0	0
...	...	...	...	...
$s_n$	1	0	0	0

Já na execução do 2º episódio...

Início	Campo	Campo	Campo
Campo	Buraco	Campo (0.0)	Buraco
Campo	Campo (0.0)	Campo	Buraco (-0.1)
Buraco	Campo	Campo (0.9)	<b>Objetivo</b>

Q-table resultante da execução do  $n$ -éssimo episódio.

<b>Q-table</b>	<i>esquerda</i>	<i>baixo</i>	<i>direita</i>	<i>cima</i>
$s_1$	0.02	0.03	0.0001	0.0001
$s_2$	0.03	-0.003	0.05	0.001
...	...	...	...	...
$s_n$	0.985	0.0001	0.003	0.002

Após a execução de  $n$  episódios o agente conhece qual a melhor ação para cada estado.

# Algoritmo Q-Learning

inicializar os valores de  $Q(s, a)$  arbitrariamente

**for** todos os episódios **do**

**repeat**

escolher uma ação  $a$  para um estado  $s$

executar a ação  $a$

observar a recompensa  $r$  e o novo estado  $s'$

$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$

$s \leftarrow s'$

**until**  $s$  ser um estado final

**end for**



## Algoritmo Q-Learning: hiperparâmetro $\alpha$

- $\alpha$  é a taxa de aprendizado ( $0 < \alpha \leq 1$ ), quanto maior, mais valor dá ao novo aprendizado.

# Algoritmo Q-Learning: hiperparâmetro $\gamma$

- Para tarefas episódicas, o retorno é fácil de ser calculado, pois será a soma de todas as recompensas obtidas pelo agente. Mas para tarefas contínuas, como a atividade não tem fim e não podemos somar até o infinito, há a necessidade da inserção de um fator de desconto ( $\gamma$ ).
- O fator de desconto ( $\gamma$ ) é um hiperparâmetro que consiste em um número entre 0 e 1 que define a importância das recompensas futuras em relação à atual ( $0 \leq \gamma < 1$ ).
- Valores mais próximos ao 0 dão mais importância a recompensas imediatas enquanto os mais próximos de 1 tentarão manter a importância de recompensas futuras.

## Explorando vs Exploitando

- A política que o agente utiliza para escolher uma ação  $a$  para um estado  $s$  não interfere no aprendizado da  $Q$ -table.
- No entanto, para que o algoritmo  $Q$ -learning possa convergir para um determinado problema é necessário que o algoritmo visite pares de ação-estado infinitas (muitas) vezes.
- Por isso, que a escolha de determinada ação em um estado poderia ser feita de forma **aleatória**.

- Porém, normalmente se utiliza uma política que inicialmente escolhe aleatoriamente as ações, e, à medida que vai aprendendo, passa a utilizar cada vez mais as decisões determinadas pela política derivada de  $Q$ .
- Esta estratégia inicia **explorando** (tentar uma ação mesmo que ela não tenha o maior valor de  $Q$ ) e termina **explorando** (escolher a ação que tem o maior valor de  $Q$ ).



## Exemplo de função para escolha de ações

A escolha de uma ação para um estado é dada pela função:

```
function escolha( $s, \epsilon$ ):  $a$   
   $rv = \text{random}(0 < rv \leq 1)$   
  if  $rv < \epsilon$  then  
    return uma ação  $a$  aleatória em  $A$   
  end if  
  return  $\max_a Q(s, a)$ 
```

O fator de exploração  $\epsilon$  ( $0 \leq \epsilon \leq 1$ ) inicia com um valor alto (0.7, por exemplo) e, conforme a simulação avança, diminui:  $\epsilon \leftarrow \epsilon \times \epsilon_{dec}$ , onde  $\epsilon_{dec} = 0.99$

# Epsilon



# Algoritmo Q-Learning

**function** Q-Learning(env,  $\alpha$ ,  $\gamma$ ,  $\epsilon$ ,  $\epsilon_{min}$ ,  $\epsilon_{dec}$ , episódios)

inicializar os valores de  $Q(s, a)$  arbitrariamente

inicializar  $s$  a partir de  $env$

**for** todos os episódios **do**

**repeat**

$a \leftarrow escolha(s, \epsilon)$

$s', r \leftarrow$  executar a ação  $a$  no  $env$

$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$

$s \leftarrow s'$

**until**  $s$  ser um estado final

**if**  $\epsilon > \epsilon_{min}$  **then**  $\epsilon \leftarrow \epsilon \times \epsilon_{dec}$

**end for**

**return**  $Q$

## Q-Learning com GridSearch

Faz sentido usar GridSearch para encontrar os melhores valores de  $\alpha$  e  $\gamma$ ?



## Considerações Finais

- O algoritmo *Q Learning* pode ser utilizado por agentes que não tem conhecimento prévio de como suas ações afetam o ambiente.
- Diversos autores já provaram que o algoritmo *Q Learning* converge para a função correta  $Q$  dentro de certas condições. Por exemplo, uma delas é garantir que o agente avalie um par  $Q(s, a)$  diversas vezes.

- *Q Learning* converge tanto para processos de decisão de Markov (MDP) **determinísticos** e **não-determinísticos**.
- Na prática, o algoritmo *Q Learning* necessita de muitas iterações de treinamento até convergir, inclusive para problemas que não tem um espaço de busca tão grande.

# Implementações

- Siga as orientações que estão no arquivo README da pasta  
<https://github.com/fbarth/ai-espm/tree/master/reinLearn>

## Material de **consulta**

- Tom Mitchell. Machine Learning. McGraw-Hill, 1997.
- Richard Sutton and Andrew Barto. Reinforcement Learning: An Introduction. Second Edition, in progress. The MIT Press, 2015.
- Projeto Gym: <https://gym.openai.com/>